

Gruppenaufgabe 3 | Deduplication Storage Appliances

Szenario

Das Spital «MediCare Bern AG» virtualisiert derzeit alle seine IT-Dienste. Das Rechenzentrum beherbergt nun 300 Windows-Server-VMs und erzeugt täglich massive Datenbank-Dumps der Patientensysteme. Das IT-Team schlägt Alarm: Das klassische Backup auf normale Festplatten dauert inzwischen über 18 Stunden, wodurch das "Backup-Fenster" in die produktive Arbeitszeit am Tag übergreift. Zudem ist der Speicherplatz restlos voll. Als IT-Spezialisten evaluieren Sie nun den Einsatz einer Deduplication Storage Appliance.

Lernziele

Nach Bearbeitung dieser Aufgabe können Sie:

- Die theoretische Funktionsweise der Daten-Deduplizierung analysieren und auf reale Szenarien übertragen.
- Die Effizienzsteigerung durch Deduplizierung bei homogenen Umgebungen (viele Windows-VMs) bewerten und argumentativ darlegen.
- Zwischen verschiedenen Architekturansätzen (Inline vs. Post-Process, Source vs. Target) unterscheiden und zielgerichtet auswählen.

Arbeitsauftrag

Erstellen Sie ein Lösungsdesign für die «MediCare Bern AG», das aufzeigt, wie eine Deduplication Appliance das Problem der überlangen Backup-Fenster und des Platzmangels löst. Legen Sie sich begründet fest, ob Sie Inline- oder Post-Process-Deduplizierung einsetzen würden und welche Datenreduktionsraten Sie für die VMs schätzen.

Ergebnis

Visualisieren Sie in Form einer Konzeptskizze (Flipchart/Digital), wie die Daten vom Server bis zur Appliance fließen und wo die Reduzierung stattfindet. Bereiten Sie eine 3-minütige Präsentation vor.

Musterlösung A | Gruppenaufgabe 3 | Deduplication Storage Appliances

Ansatz: Strukturiert-analytisch

Problemdefinition und Ausgangslage

Die «MediCare Bern AG» kämpft mit den klassischen Symptomen exponentiellen Datenwachstums in einer unzureichend dimensionierten Architektur:

1. Das Backup-Fenster wird gerissen (Dauer > 18 Stunden), was zu massiven Performance-Einbussen bei den produktiven Systemen während der Hauptarbeitszeit führt.

2. Der physische Speicherplatz des Backup-Target ist vollständig erschöpft.
3. Die Ursache liegt in der Sicherung von 300 virtuellen Windows-Maschinen sowie täglich identischen Voll-Dumps grosser Datenbanken. Diese Datensätze weisen von Natur aus eine gigantische Redundanz auf.

Technologische Lösung: Einsatz einer Deduplication Storage Appliance

Die Einführung einer spezialisierten Hardware-Appliance (z. B. Dell Data Domain, HPE StoreOnce) am Zielort (Target) bietet die passgenaue Lösung für beide Kernprobleme.

Erwartete Deduplizierungsraten (Schätzung):

- Virtuelle Maschinen (300x Windows Server): Da alle 300 VMs denselben Betriebssystemkern (z. B. Windows Server 2022) nutzen, sind Millionen von Systemdateien (DLLs, System32-Dateien) exakt identisch. Die Appliance speichert diese Dateien nur ein einziges Mal und erstellt für die verbleibenden 299 VMs lediglich winzige Pointer (Zeiger). Hier ist eine Datenreduktion von **80% bis 90% (Faktor 10:1 bis 20:1)** äusserst realistisch.
- Tägliche Datenbank-Dumps: Da sich eine Spitaldatenbank von einem Tag auf den anderen prozentual nur geringfügig ändert (neue Patienteneinträge), sind 95% des Dumps identisch zum Vortag. Auch hier werden Deduplizierungsraten von **bis zu 95% (Faktor 20:1)** erreicht.

Auswirkung auf die Speicherkapazität:

Durch den massiven Wegfall redundanter Datenblöcke wird der benötigte Speicherplatz drastisch reduziert. Anstelle von beispielsweise 100 Terabyte täglich müssen effektiv nur noch 5 bis 10 Terabyte an physischen Blöcken auf die Festplatten der Appliance geschrieben werden. Das Problem des Speicherplatzmangels ist somit nachhaltig gelöst.

Architektur-Entscheidung: Source- vs. Target-Deduplizierung

Wir empfehlen den Einsatz von **Source-Deduplizierung** in Kombination mit einer leistungsstarken Appliance (wie z. B. der Veeam/Data Domain Boost Technologie).

- Begründung: Wenn die 300 VMs alle ihre Daten über das Netzwerk an das Backup-System senden, bricht das Netzwerk zusammen – daher die 18 Stunden Backup-Dauer. Bei der Source-Deduplizierung berechnet bereits die Backup-Software auf den Spital-Servern die Hash-Werte der Datenblöcke und fragt die Appliance: "Kennst du diesen Block schon?". Die Appliance antwortet mit "Ja", woraufhin der Datenblock *nicht* mehr über das Netzwerk gesendet, sondern nur der Metadaten-Zeiger aktualisiert wird.
- Resultat: Das Netzwerk wird extrem entlastet. Das Backup-Fenster schrumpft von 18 Stunden auf voraussichtlich 2 bis 4 Stunden, da nur noch die tatsächlich neuen Datenblöcke über das LAN transportiert werden.

Architektur-Entscheidung: Inline vs. Post-Process

Innerhalb der Appliance entscheiden wir uns für das **Inline-Verfahren**.

- Begründung: Beim Inline-Verfahren erfolgt die Deduplizierung im Arbeitsspeicher der Appliance in Echtzeit, bevor die Daten auf die Disk geschrieben werden. Dies erfordert zwar leistungsstarke CPUs in der Appliance, hat aber den gewaltigen Vorteil, dass überhaupt kein temporärer (redundanter) Zwischenspeicher ("Landing Zone") benötigt wird. Angesichts des akuten Platzmangels der MediCare Bern AG scheidet Post-Process (welches die Daten zuerst unkomprimiert speichert und später aufräumt) faktisch aus.

Risikobetrachtung (Performance beim Restore)

Das grösste Risiko dieses Ansatzes ist die sogenannte "Rehydrierung" (Wiederherstellung) der Daten. Wenn das Spital eine komplette 1-Terabyte-Datenbank wiederherstellen muss, muss die Appliance das File aus Millionen verstreuter, referenzierter Blöcke erst wieder aufwendig zusammensetzen. Dies kostet CPU-Zeit und führt zu einer längeren Restore-Dauer als bei einem herkömmlichen Festplatten-Storage. Diese verlängerte Recovery Time Objective (RTO) muss im Notfallplan des Spitals zwingend berücksichtigt und kommuniziert werden.

Musterlösung B | Gruppenaufgabe 3 | Deduplication Storage Appliances

Ansatz: Praxisnah-narrativ

Konzeptskizze und Management-Erläuterung für die MediCare Bern AG

Liebes IT-Team der MediCare Bern AG. Wir haben Ihre Notlage analysiert. Ihr Backup läuft 18 Stunden lang und das Storage platzt aus allen Nähten. Die gute Nachricht: Sie haben kein echtes Datenproblem, Sie haben ein Redundanzproblem. Wir werden Ihnen heute aufzeigen, wie eine Deduplication Storage Appliance dieses Problem elegant und dauerhaft löst.

Die Ausgangslage: Warum das Backup so lange dauert

Lassen Sie uns betrachten, was Sie aktuell tun: Sie sichern jede Nacht 300 virtuelle Windows-Maschinen. Eine Windows-Installation ist rund 20 Gigabyte gross. Das bedeutet, Sie kopieren jede Nacht 300 Mal exakt denselben Windows-Kern (Dateien, Updates, Standard-Software) über das Netzwerk auf Ihre Backup-Festplatten. Das sind 6 Terabyte an reiner Windows-Installation, die Sie Nacht für Nacht stur kopieren. Hinzu kommen die grossen Datenbank-Exporte, die jeden Tag zu 95% exakt gleich aussehen wie gestern.

Sie verstopfen Ihr Netzwerk und Ihre Festplatten mit Millionen von identischen Datenblöcken. Kein Wunder, dauert das 18 Stunden.

Die Lösung: Wie die Deduplication Appliance arbeitet

Wir integrieren eine spezielle Hardware – eine Deduplication Appliance – in Ihr Netzwerk. Diese

Maschine ist kein einfaches "dummes" Festplatten-Kistchen, sondern eine intelligente Rechenmaschine mit sehr starken Prozessoren.

Sie funktioniert wie ein eifriger Bibliothekar: Wenn die erste Windows-VM gesichert wird, speichert die Appliance jeden Datenblock auf die Festplatte und notiert sich den Inhalt in einem Index (einer gigantischen Tabelle). Kommt nun die zweite Windows-VM, vergleicht der Bibliothekar jeden eintreffenden Block mit seinem Index. Er merkt sofort: "Halt, diesen Block von Windows kenne ich schon, den habe ich auf Festplatte 1 liegen." Er verwirft den neuen Block und schreibt einfach einen winzigen Vermerk in sein Buch: "VM Nummer 2 nutzt übrigens auch diesen Block".

Dies passiert bei allen 300 Maschinen. Die Appliance speichert das eigentliche Windows-Betriebssystem nur noch *ein einziges Mal*. Für die restlichen 299 Maschinen speichert sie nur winzige Textverweise. Die Platzersparnis ist magisch: Wir gehen davon aus, dass Sie Ihren Speicherbedarf sofort um fast 90 Prozent reduzieren werden.

Die Umsetzung: Inline-Deduplizierung

Es gibt zwei Methoden, wie die Appliance das tun kann. Entweder sie nimmt die Daten unkomprimiert entgegen, speichert sie und räumt in der Nacht auf (Post-Process) – das scheidet aus, da Sie ohnehin keinen freien Speicherplatz mehr haben.

Deshalb nutzen wir die "Inline-Deduplizierung". Die Daten werden in Echtzeit noch im Arbeitsspeicher der Appliance geprüft, aussortiert und nur das, was absolut einzigartig und neu ist, darf auf die Festplatte geschrieben werden.

Das Backup-Fenster retten (Source-Side Deduplication)

Damit wir Ihr 18-Stunden-Problem lösen, gehen wir noch einen Schritt weiter. Wir installieren auf Ihren Backup-Servern eine smarte Software-Erweiterung. Diese sorgt dafür, dass die Server bereits vor dem Senden über das Netzwerk bei der Appliance nachfragen: "Appliance, ich habe hier Block A, B und C, welche kennst du schon?". Die Appliance antwortet: "A und B kenne ich. Schick mir nur C."

Dadurch wandern statt hunderten von Terabytes plötzlich nur noch ein paar wenige Gigabyte an Änderungen durch Ihr Netzwerk. Das Netzwerk wird massiv entlastet. Ihr Backup, das heute 18 Stunden dauert, wird künftig voraussichtlich in 2 bis 3 Stunden tief in der Nacht abgeschlossen sein, lange bevor die ersten Ärzte am Morgen das System belasten.

Ein ehrliches Wort zum Schluss (Trade-offs)

Diese Genialität hat ihren Preis in der Wiederherstellung. Wenn ein Arzt eine versehentlich gelöschte VM zurückhaben will, kann die Appliance die Datei nicht einfach am Stück

zurückkopieren. Sie muss erst ihr Logbuch lesen, die Millionen von Puzzleteilen (Blöcken) aus den Festplatten zusammensuchen und die Maschine wieder "aufblasen". Dieser Vorgang (Rehydrierung) dauert merklich länger als bei Ihrem alten System. Da Sie VMs aber glücklicherweise nur extrem selten komplett wiederherstellen müssen, ist dieser Zeitverlust im Katastrophenfall ein absolut vertretbarer Preis für die Rettung Ihres täglichen operativen Betriebs. Wir empfehlen die zügige Beschaffung.